

Deep Learning

CNN 모델 개요

강사 양석환



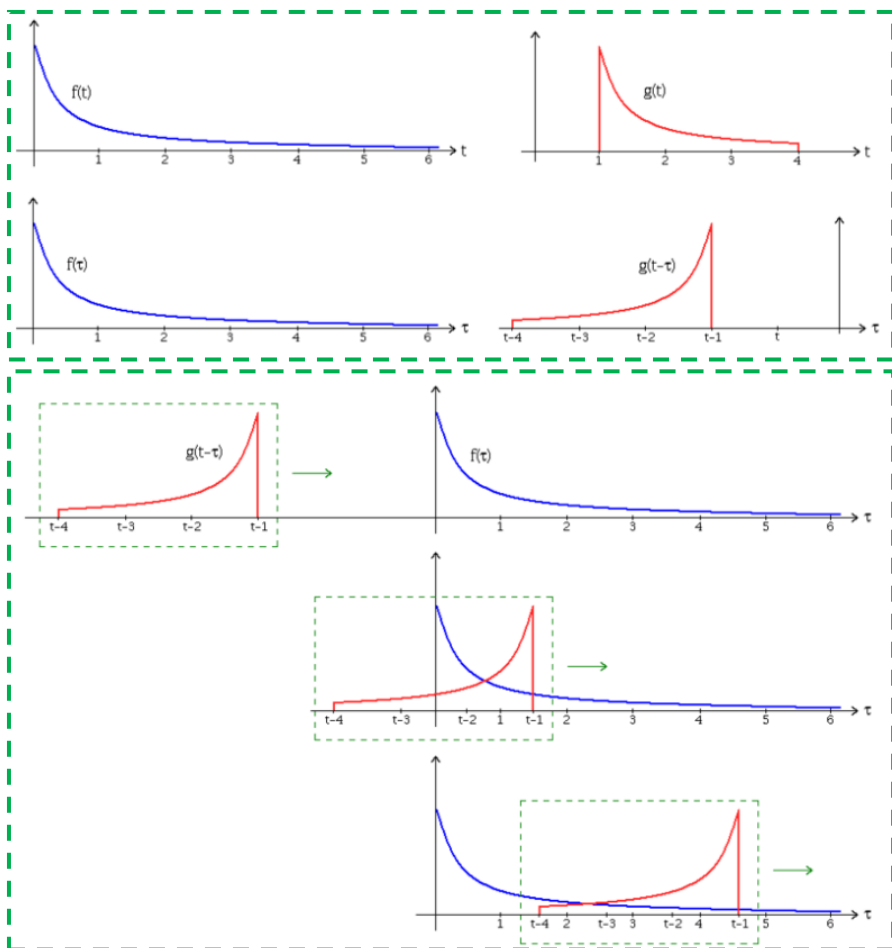
CNN 모델의 구조와 이해



- **CNN (Convolutional Neural Network) 모델**

- 최근의 영상 인식, 처리 분야에 있어서 가장 기본이 되는 모델
- 눈과 뇌에서 처리되는 신경과학적 시각처리 방식에서 고안한 모델
- 신경망 동작을 처리하기 위하여 합성곱 연산을 이용함
 - 합성곱: 두 개의 함수가 있을 때, 둘 중에서 하나의 함수를 반전, 이동(전이)시킨 후, 두 함수를 곱한(결합한) 결과를 적분하여 그 파형(그래프)을 얻는 연산 방법
 - CNN 모델에서는 합성곱 연산을 기반으로 각 영역(픽셀)이 서로 얼마나 일치하는지 계산하여 그 계산 결과를 활용함

• Convolution (합성곱)



반전

결과 예시

전이 + 결합





그림 출처: 위키피디아

• Convolution (합성곱)

- 합성곱 신경망에서는 “하나의 함수가 다른 함수와 얼마나 일치하는가?”의 의미로 사용
- 하나의 필터(커널)에 대하여 이미지의 각 부분들이 필터와 얼마나 일치하는지 계산




- ① 각 요소를 1:1 대응으로 곱한 후 총합 계산


$$(-1 + 1 + 1) + (1 + 1 + 1) + (1 + 1 + 1) = 7$$
- ② 총합을 필터의 요소 개수(9개)를 기준으로 평균 계산

$$7 / 9 = 0.777777..$$

그림 출처: "파이토치 첫걸음" (최건호 저, 한빛미디어)

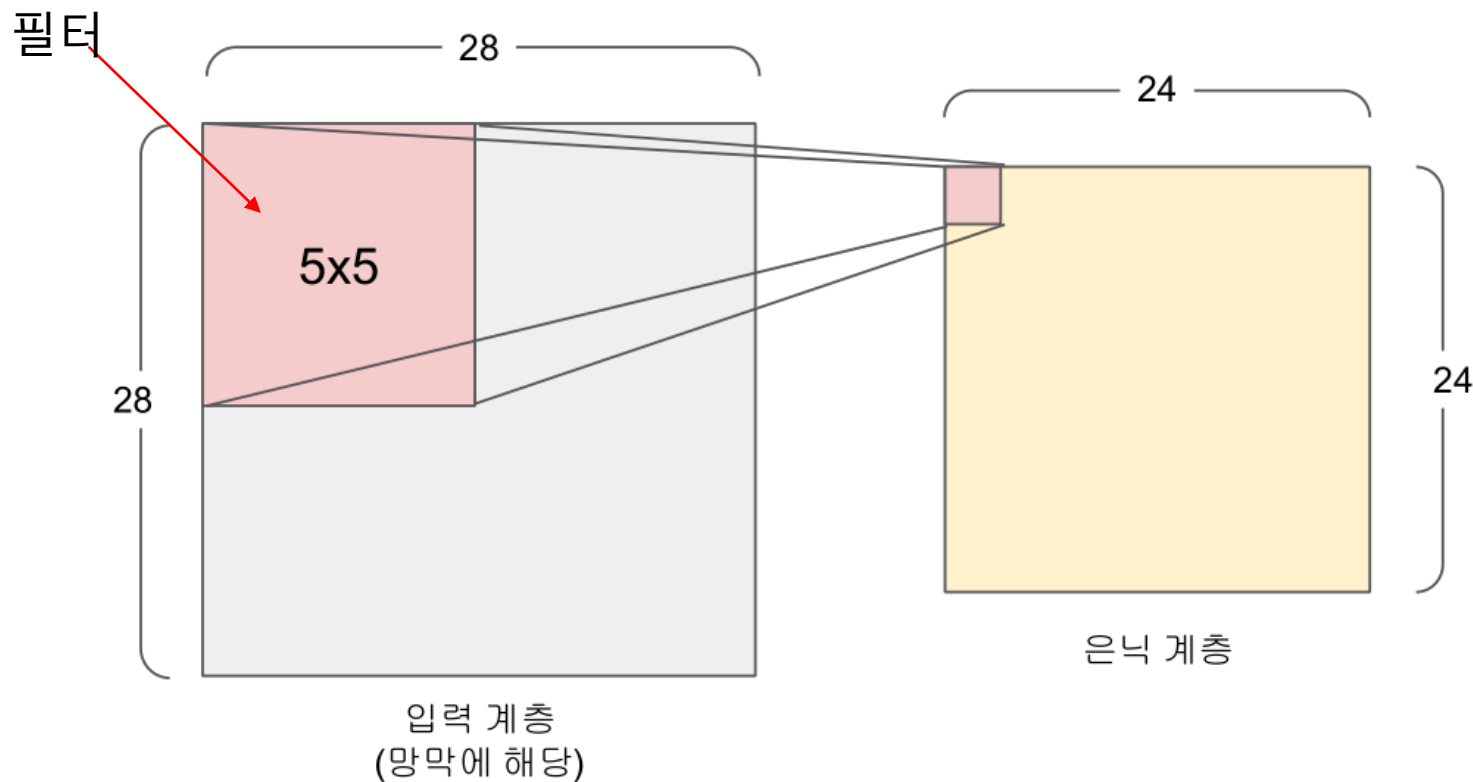
- CNN (Convolutional Neural Network) 모델
 - Convolution(합성곱) 을 이용하여 가중치 수 줄임 → 연산량 감소와 효과적인 이미지 처리 수행
 - Convolution Filter 를 이용하여 신경망 동작 수행
 - Convolution Layer 와 Fully Connected Layer 를 중심으로 영상정보 처리
 - Convolution Layer : 특징점을 효과적으로 찾는 데 활용
 - Fully Connected Layer : 발견한 특징점을 기반으로 이미지를 분류하는 데 활용






- Convolution Layer - Pooling Layer의 반복
- 반복 방식은 사용자가 임의로 결정 (예, Convolution Layer만 여러 층을 가진 후 마지막에 Pooling Layer가 오는 경우도 있음)
- 국소/지역 콘트라스트 정규화 (Local Contrast Normalization, LCN) 층을 매치하는 경우도 있음

- 목적: 테두리, 선, 색 등 이미지의 시각적 특징이나 특성 감지




- 입력 계층과 은닉계층이 1:1 매핑되지 않음
- 시각피질의 수용야에 해당하는 윈도우는 정해진 크기만큼 좌표를 이동하며 입력계층의 데이터를 탐색함
- 픽셀 차이를 입력 계층과 겹쳐가며 이동하는데 이 간격을 스트라이드라고 함
- 필터의 크기(윈도우)가 $5 \times 5 = 25$ 인 경우는 25개의 픽셀이 하나의 뉴런에 대응됨

- 스트라이드에 따른 이동



- 패딩

- 더 좋은 결과를 내기 위하여 윈도우를 이미지 영역 밖으로 확장할 때 사용



- Convolution Layer에서의 연산


- Convolution, 즉 합성곱이란 이미지와 필터 사이에 정의되는 합성곱 연산을 말함
- 이미지의 합성곱은 필터의 명암 패턴과 유사한 명암 패턴이 입력된 이미지의 어디에 있는지 검출하는 작용, 즉 필터가 나타내는 특징적인 명암 구조를 이미지로부터 추출하는 작용을 함
- 필터: 커널이라고도 함
 - 입력층의 윈도우를 은닉층의 뉴런 하나로 압축할 때, Convolution Layer에서는 윈도우의 크기만큼의 가중치와 1개의 편향 값(bias)을 적용
 - 예를 들어 윈도우의 크기가 5x5라면 5x5개의 가중치와 1개의 편향 값이 필요함
 - 이 5x5개의 가중치와 1개의 편향 값을 커널, 또는 필터라고 부름
 - 필터는 해당 은닉층을 만들기 위한 모든 윈도우에 공통으로 적용됨

• 필터 사용의 장점

- 가중치의 수를 줄임으로써 전체 연산량을 대폭 감소시킬 수 있음
- 예를 들어, 입력층의 크기가 28×28 일때 기본 신경망의 경우 $28 \times 28 = 784$ 개의 가중치를 찾아야 하지만 Convolution Layer 에서는 5×5 개인 25 개의 가중치만 찾으면 됨
- 연산량의 대폭 감소로 학습이 더 빠르고 효율적으로 진행됨
- 단점
 - 복잡한 특징을 가진 이미지의 분석이 어려움
 - 보완책으로서 여러 개의 필터를 사용하며, 분석하고자 하는 내용에 따라 필터의 개수를 어떻게 정하는가 하는 것이 중요함

- Convolution Layer 와 Pooling Layer 의 관계 및 역할

- 이미지 데이터, 즉 2 차원의 평면 행렬에서 지정한 영역의 값들을 하나의 값으로 압축
- 압축할 때
 - Convolution Layer: 가중치와 편향을 적용
 - Pooling Layer: 값들 중 하나를 선택해서 가져오는 역할




- Convolution Layer에서 해당 영역 내의 영상 위치가 다소 변경되더라도 인식할 수 있도록 함
- Max Pooling, Average Pooling이 많이 사용됨

- 국소 콘트라스트(대비) 정규화

- 자연물 이미지 등 주변의 조명, 카메라의 노출 등 환경 변화에 따라 이미지 전체의 밝기, 대비가 크게 변하는 경우 사용함

- 이미지 밝기 정규화의 방법

- 이미지의 집합(훈련 데이터)에 대한 통계치를 이용하여 이미지의 명암을 전체적으로 조절
- LCN
 - 이미지 한 장, 한 장에 대하여 개별적으로 조절
 - 고정된 가중치를 사용하므로 학습 가능한 파라미터는 없음








• 활용도

- 일반적으로 기존의 신경망에서 각 층별 연결에 사용되는 방식. 전결합층
- 모든 노드를 연결하므로 수많은 연산이 일어남
- CNN의 특징은 모든 노드를 결합하지 않음으로써 연산량을 줄여 효율성을 높이는 방식
- 그럼 왜 사용하는가?
 - 모든 노드를 연결하므로 1차원배열로 표시됨 → 이미지의 공간정보가 사라짐
 - 최종 결과값은 분류 결과 도출 □ 결국 마지막에 도출된 분류결과 Label을 선택하여야 함
 - 최종 결과를 분류하기 위한 기반 정보는 모두 가지고 있어야 분류를 위한 SoftMax 함수를 사용할 수 있음
- 필수는 아니며 Convolution Layer의 결과를 그대로 사용할 수도 있음

• 활성화 함수


- 실제 신경망에서는 우리 몸에서 반응할 필요가 있는 수준 까지만 신호를 전달하고 나머지의 신호는 무시 → 비선형적 특징
- 합성곱 연산은 입력과 가중치로 이루어진 연산 → 선형성을 가짐 → 비선형 특성 부여를 위하여 활성화 함수가 필요함
- 최근 많이 사용되는 활성화 함수는 ReLU(Rectified Linear Unit) 계열의 함수







뇌의 시각정보 처리 과정과 CNN 모델








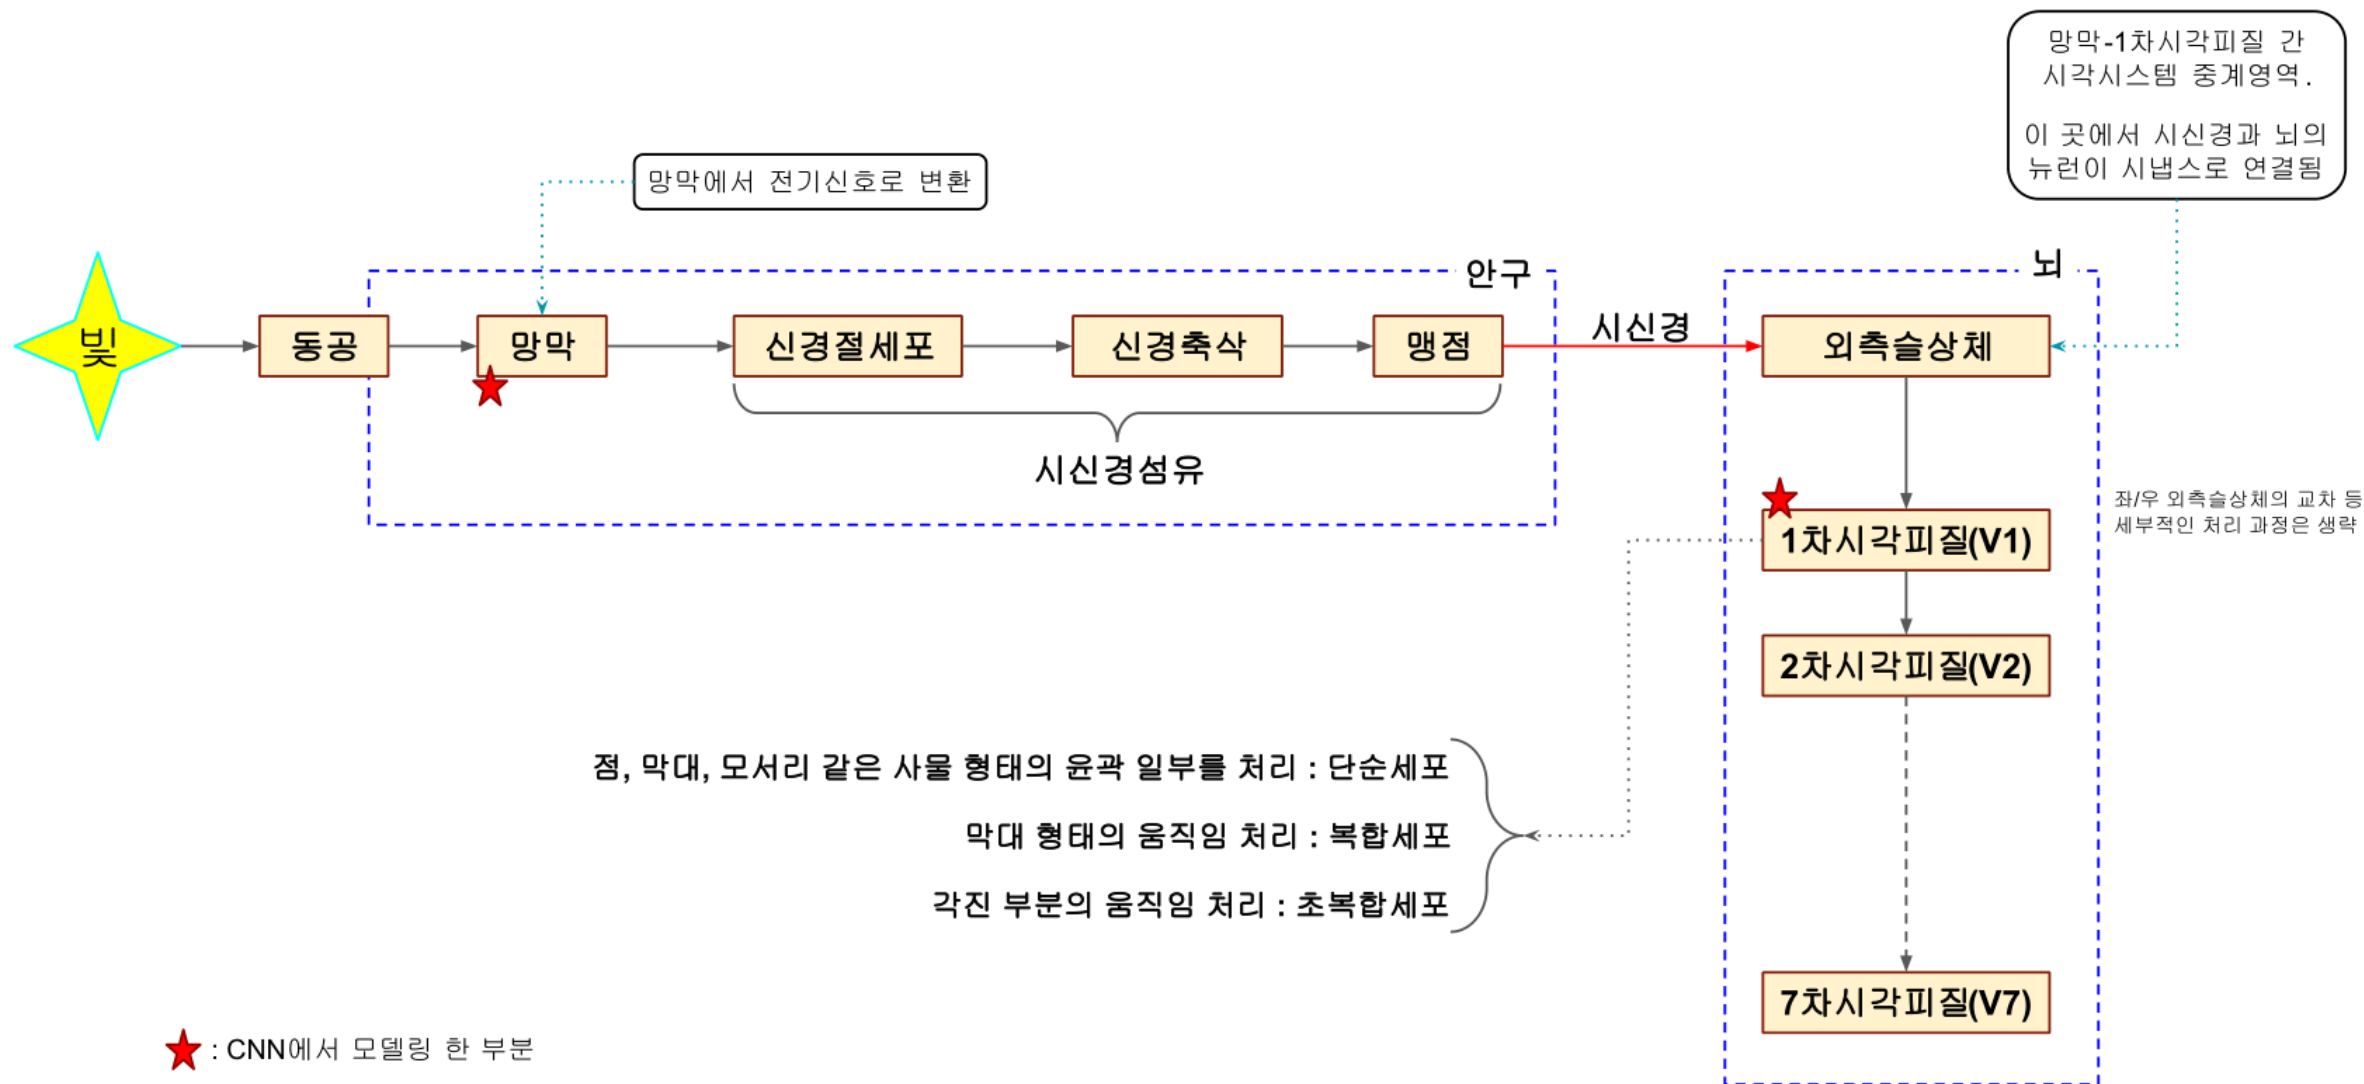
- 아주 좁은 영역이지만 가장 세밀하고 선명하게 빛을 인식함
- 중심와에는 원추세포가 가장 밀집되어 있음
- 중심와에서 멀어질수록 원추세포의 밀집도는 떨어지고 간상세포가 늘어남



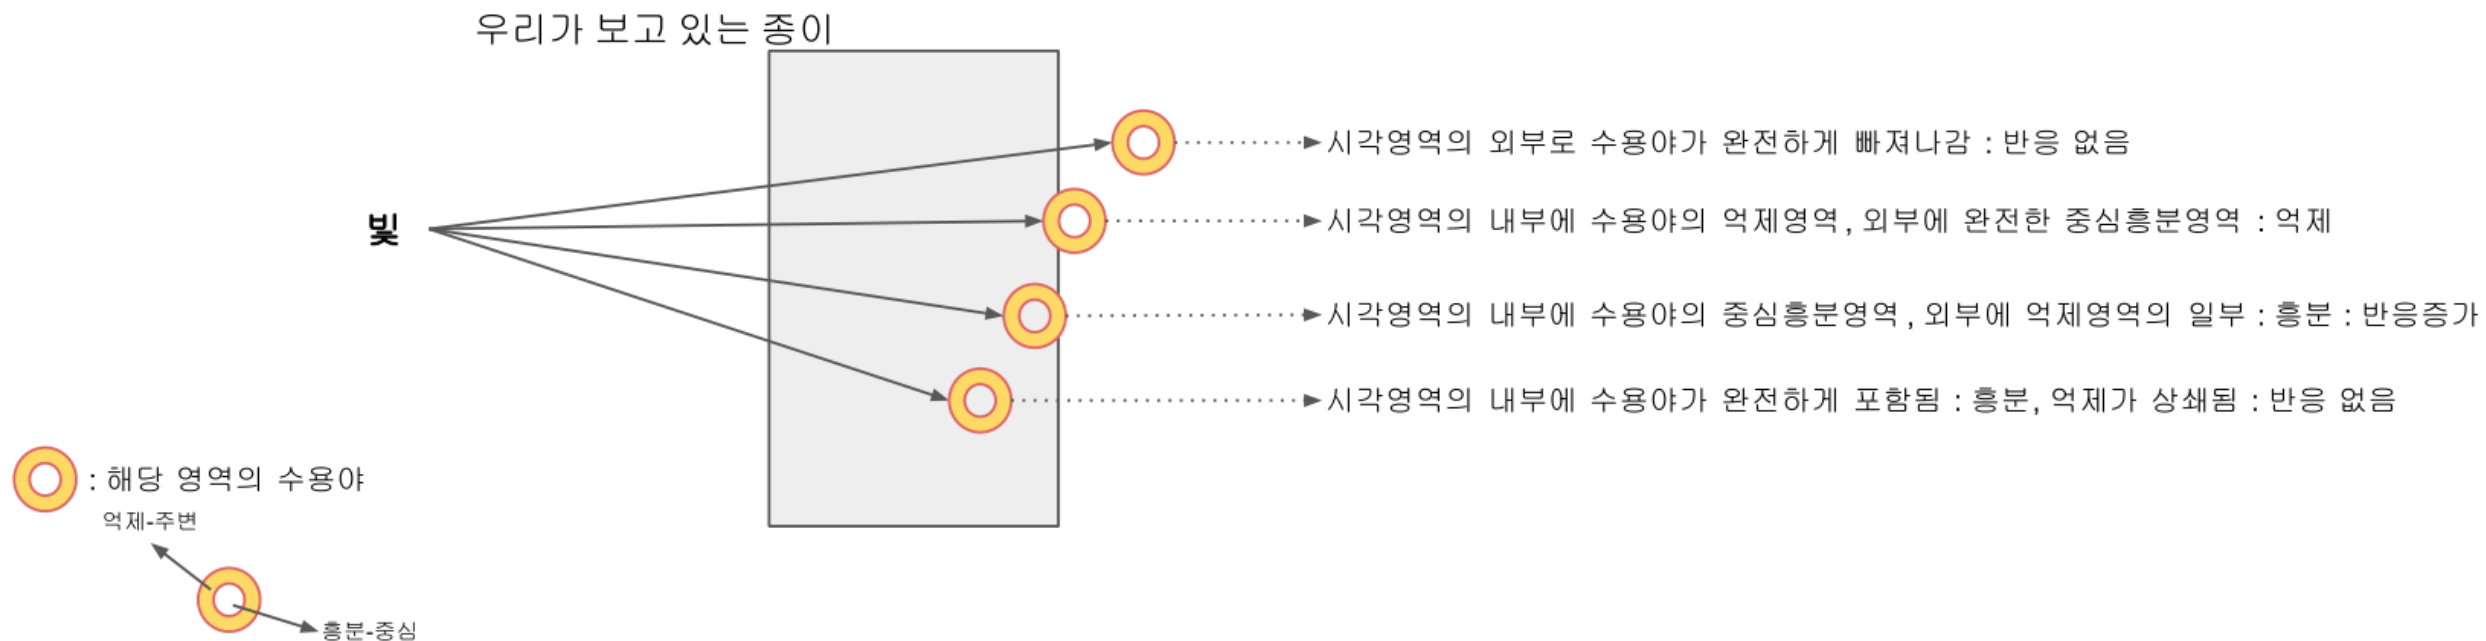
- 눈의 잘못된 진화(?)와 노이즈 캔슬링 기능
→ 인간의 몸에서 찾아볼 수 있는 전자/기계적 예를 볼 수 있다.



- 광수용세포는 빛에 대해 화학적으로 반응하는 광색소 함유
- 색채를 지각하는 원추세포, 명암을 탐지하는 간상세포
- 각 원추세포마다 다른 광색소를 함유함 (적색, 녹색, 청색)
- 빛이 광수용세포에 닿으면 광색소의 생화학적 특성에 따라 전위 변화가 발생하고 이온 투과성을 변경시킴
- 이온 투과성의 변화에 따라 광수용세포에서 신경전달물질이 분비되며 이로 인하여 전기 신호가 발생, 전달됨



- 안구에서 신경절 세포는 마지막 출력에 해당하는 영역, 뉴런과 동일한 방식으로 동작함
- 망막에서 전기신호로 변환된 시각 정보는 신경절 세포의 반응률에 영향을 미침
- 신경절 세포의 반응률에 영향을 미치는 망막 표면의 영역을 해당 세포의 수용야(Receptive Field) 라고 하며 “중심흥분+ 주변억제” 와 “중심억제+ 주변흥분” 의 두 가지 형태가 존재함



• 시각피질에서의 시각정보 처리

• 1 차 시각피질의 세포들


- 단순세포: 국소적인 영역을 보고, 단순한 패턴에 자극을 받는 세포
→ 점, 막대, 모서리 같은 사물 형태의 윤곽 일부를 처리
- 복합세포: 넓은 영역을 보고, 복잡한 패턴에 자극을 받는 세포 → 막대 형태의 움직임 처리
- 초복합세포: 각진 부분(모서리)의 움직임 처리

• 각 세포들은 수직으로 세워놓은 기둥 형태로 조직되어 있음(시각피질에서만 이런 형태)


• 각 세포들은 서로 다른 방향의 자극에 대해 반응함

- 시각피질에서 이러한 기둥 조직에 의해 방향성 정보를 부호화 하는 것이 시각적 공간을 뉴런에 의해서 재구성하는데 매우 중요한 역할을 하는 것으로 추정됨
- 세포기둥은 세포들의 단순한 집합이 아니라 역동적 기능 단위이다

- 단순세포: 엄격한 위치 선택성을 가짐 (정확한 입력패턴에 반응)
- 복합세포: 입력패턴을 조금 벗어나도 반응함
- 단순세포와 복합세포의 반응성을 모형화 하면:




중간층 각 유닛은 입력층의 $4 \times 4 = 16$ 개의 유닛하고만 결합, 출력층 유닛은 중간층 유닛 $3 \times 3 = 9$ 개의 유닛 중 하나라도 활성화되면 활성화




중간층의 유닛은 입력 패턴의 위치에 민감하지만, 출력층의 유닛은 범위 안에서 둔감함(하나라도 활성화되면 자기도 활성화)

- 눈과 시각피질 사이의 시각정보 처리 방식에서 개념 도입
 - 망막에서의 빛 인식 영역 → 입력층
 - 시각피질의 단순세포에 의한 입력패턴 대응 영역 → 중간층
 - 시각피질의 복합세포에 의한 활성화 및 차원축소 영역 → 출력층
 - 해당 영역에 대한 수용야(감수영역이라고도 함) → 필터
 - 수용야의 영역 크기 → 윈도우
 - 수용야의 이동 범위 → 스트라이드
 - 수용야의 영역 처리 → 패딩
- 시각 처리 신경망은 단순세포와 복잡세포가 층을 이루어 구성되었고, 층간 연산에 따라 동작하는 것으로 관찰되고 있으며, CNN 모델은 이를 반영하고 있음

시각의 전달 경로 (CNN과 비교해보자)



일차시각피질의 모듈 중 하나



2차 출처: <http://www.seehint.com/word.asp?no=13222>

CNN 모델과 DNN 모델의 차이



- CNN 모델과 DNN 모델은 기본적으로 같다

- 동일한 학습 방법을 따름

- 모든 층에 대하여 추측을 할 때는 Forward Propagation 수행

- 모든 층에 대한 가중치(Weight)를 훈련할 때는 Back Propagation 수행

- 다른 점

- DNN 모델

- 목적: 입력에 대하여 원하는 결과가 나올 수 있도록 가중치를 갱신(훈련, 학습)하는 것


- 학습: 각 노드에 대한 가중치를 학습함

- CNN 모델

- 목적: 합성곱(Convolution) 층을 이용하여 유의미한 특징(Feature)을 추출하여 이용하는 것


- 학습: 각 특징에 대한 가중치를 학습함

- 이미지에서 필터의 특징을 가진 영역을 추출(인식)



- 필터A: 수직의 edge를 검출하는 필터 → 보다 큰 값이 있는 위치에 수직의 edge가 있다는 것을 의미함
- 각 층에서 Back Propagation을 수행할 때
 - 예측 값과 실제 값을 비교한 오차를 정의(계산)한 후, 각 edge의 가중치를 갱신함

- 합성곱 층(Convolution Layer)에서의 연산과 DNN 모델에서의 연산의 차이
 - 기본적으로 가중치가 고정되어 있음
 - 같은 필터를 이미지 전체에 적용하기 때문
 - 전 결합(Fully Connected) 그래프가 아님
 - 필터를 이미지 전체에 적용하는 것이 아니기때문에
 - 어느 픽셀이 어느 출력 픽셀에 영향을 주는지 추적해야 함
 - 즉 모델의 각 노드에서 적용되는 필터에 따른 가중치의 연산과 갱신이 이루어짐



CNN 모델 기반의 영상 처리



- 전통적인 영상 처리 방법

- 수동으로 설계된 특징 추출기를 사용 → 특징 추출 능력 및 범위의 적용에 한계가 있음

- CNN 모델

- 데이터로부터 직접 특징을 학습 → 더 복잡한 패턴 학습 가능, 다양한 문제에 더 유연하게 적용 가능
 - 이미지의 공간 구조를 인식하고 학습할 수 있음
 - 파라미터 공유로 인해 효율적인 학습이 가능함

• 개념

- 주어진 이미지가 어떤 카테고리에 속하는지 판단하는 과정
- 이미지 전체를 한 카테고리로 분류

• 기술적/구조적 특징

- 영상 분류에서는 이미지 전체를 분석하여 하나의 레이블로 분류함
- 일반적인 CNN 구조가 사용됨
- 마지막 출력 층에서 소프트맥스 활성화 함수 등을 사용하여 카테고리별 확률을 계산함



분류결과: 고양이(98%)

• 개념

- 주어진 이미지가 어떤 카테고리에 속하는지 판단하는 작업
- 이미지 내 객체의 위치와 카테고리를 동시에 찾는

• 기술적/구조적 특징

- 검출은 이미지 내의 여러 객체를 찾아야 하므로, 로컬 영역에서의 패턴을 파악해야 함
- YOLO, SSD와 같은 특수한 구조를 사용하여 객체의 경계 상자와 함께 클래스 레이블을 예측




• 개념

- 이미지의 각 픽셀이 어떤 카테고리에 속하는지 판단하는 작업
- 이미지의 각 픽셀 별로 카테고리 할당

• 기술적/구조적 특징

- 이미지의 각 픽셀에 레이블을 할당해야 하므로, 공간 정보를 잘 보존해야 함
- U-Net과 같은 구조가 사용됨
- 업샘플링과 다운샘플링을 통해 고해상도의 세그멘테이션 맵을 생성함

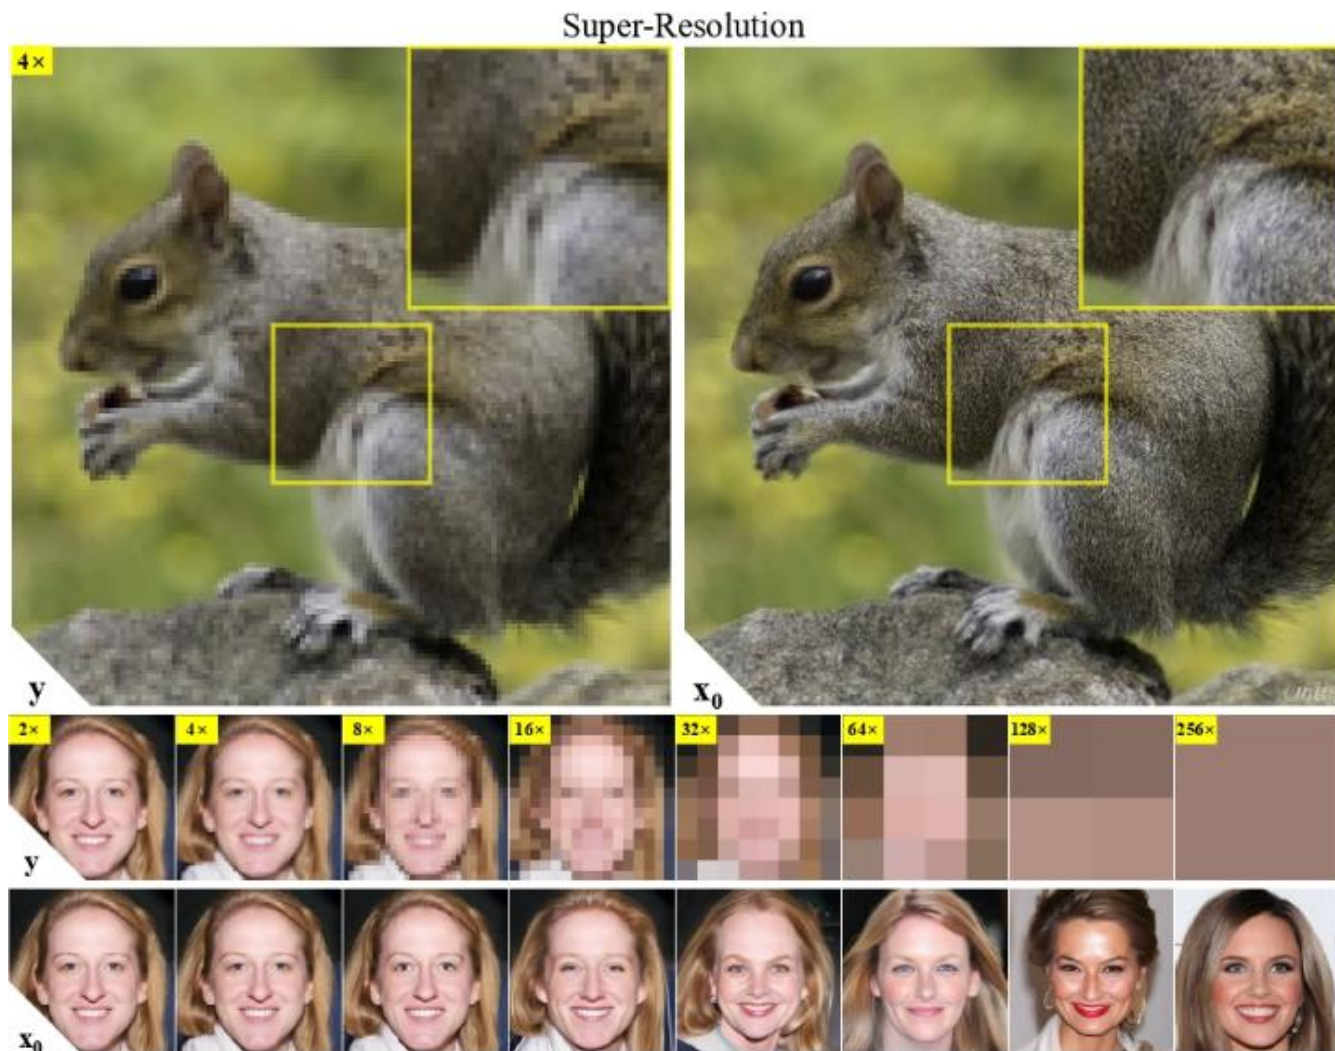


• 개념

- 영상 복원은 손상된 또는 왜곡된 이미지를 복원하는 작업
 - 노이즈 제거, 해상도 향상 등
- 손상된 이미지 복원

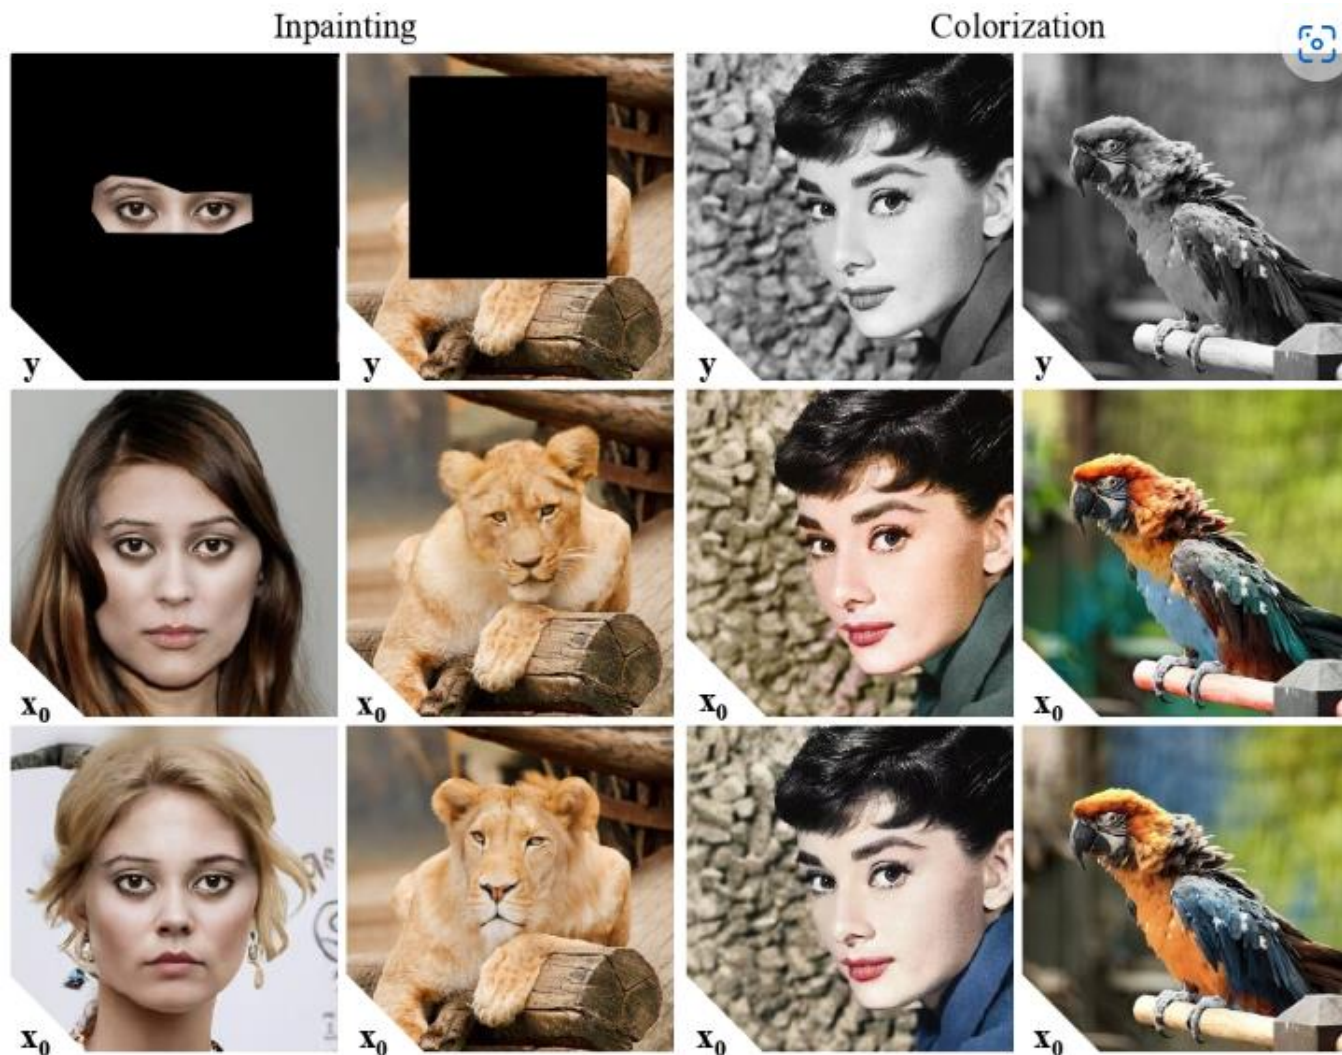
• 기술적/구조적 특징

- 원래 이미지의 특성을 복구해야 하므로, 손실함수와 네트워크 구조가 복잡할 수 있음
- SRCNN, GAN 등의 고급 기술을 사용하여 이미지의 본래 특성을 복원함



(a) Robust to arbitrary scales with realness and strict data consistency

현실성과 엄격한 데이터 일관성을 갖춘
임의의 척도에 대하여 강력한 지원을 보여줌



(b) Diverse tasks with diverse results

다양한 성과를 가진 다양한 업무

- 일부의 영상을 이용하여 전체 사진 복원
- 손상된 영역의 복원
- 컬러화
- 실제 데이터 기반의 색상의 현실화



(c) Robust to synthetic/real-world noise

합성/실제 노이즈에 강함



(d) Flexible in solving complex degradation

복잡한 열화 문제를 유연하게 해결



(e) Support arbitrary scale

임의의 척도를 지원 → 고해상도 변환 지원

THANK
YOU

